МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) МО ЭВМ

ОТЧЕТ

по лабораторной работе №7
по дисциплине «Искусственные нейронные сети»
«Классификация обзоров фильмов»

Студент гр. 8383	 Костарев К.В.
Преподаватель	Жангиров Т.Р

Санкт-Петербург

Цель работы.

Классификация последовательностей — это проблема прогнозирующего моделирования, когда у вас есть некоторая последовательность входных данных в пространстве или времени, и задача состоит в том, чтобы предсказать категорию для последовательности. Проблема усложняется тем, что последовательности могут различаться по длине, состоять из очень большого словарного запаса входных символов и могут потребовать от модели изучения долгосрочного контекста или зависимостей между символами во входной последовательности. В данной лабораторной работе также будет использоваться датасет IMDb, однако обучение будет проводиться с помощью рекуррентной нейронной сети

Постановка задачи.

- 1. Ознакомиться с рекуррентными нейронными сетями
- 2. Изучить способы классификации текста
- 3. Ознакомиться с ансамблированием сетей
- 4. Построить ансамбль сетей

Выполнение работы.

Для классификации загружается датасет IMDb. Будем рассматривать 10000 самых часто встречающихся в датасете слов. Для дальнейшего кодирования отзывов необходимо, чтобы они все были одинаковой длины, 3 поэтому короткие последовательности дополним до 500 слов нулями, а длинные – усечем до 500 слов.

Будем конструировать векторное представление слов с помощью слоя Embedding. Этот слой отображает целочисленные индексы слов в векторы, соответствующие словам. Слой обучается так, чтобы создаваемое им векторное пространство лучше отражало семантические связи между словами.

В этой работе необходимо построить ансамбль сетей, поэтому были созданы четыре модели. Каждая из моделей обучена только на части исходной обучающей выборки. Ниже приведена архитектура каждой из моделей и достигаемая моделью точность на тестовой выборке.

Mодель 1: Model: "sequential"

Layer (type)	Output Shape	Param #
embedding (Embedding)	(None, 500, 32)	320000
conv1d (Conv1D)	(None, 500, 32)	3104
max_pooling1d (MaxPooling1D)	(None, 250, 32)	0
lstm (LSTM)	(None, 100)	53200
dense (Dense)	(None, 1)	101
=======================================		========

Total params: 376,405 Trainable params: 376,405 Non-trainable params: 0

```
Epoch 1/2
```

accuracy: 0.6704 - val_loss: 0.3519 - val_accuracy: 0.8472

Epoch 2/2

accuracy: 0.8935 - val_loss: 0.3983 - val_accuracy: 0.8397

Accuracy: 83.97%

Mодель 2: Model: "sequential_1"

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, 500, 32)	320000
flatten (Flatten)	(None, 16000)	0
dense_1 (Dense)	(None, 50)	800050
dropout (Dropout)	(None, 50)	0

dense_2 (Dense)	(None, 50)	2550
dropout_1 (Dropout)	(None, 50)	0
dense_3 (Dense)	(None, 50)	2550
dense_4 (Dense)	(None, 1)	51

Total params: 1,125,201 Trainable params: 1,125,201 Non-trainable params: 0

Epoch 1/2

accuracy: 0.5269 - val_loss: 0.6550 - val_accuracy: 0.6119

Epoch 2/2

accuracy: 0.8378 - val_loss: 0.3411 - val_accuracy: 0.8536

Accuracy: 85.36%

Модель 3:

Model: "sequential_2"

Layer (type)	Output Shape	Param #
embedding_2 (Embedding)	(None, 500, 32)	320000
simple_rnn (SimpleRNN)	(None, 500, 32)	2080
simple_rnn_1 (SimpleRNN)	(None, 32)	2080
dense_5 (Dense)	(None, 1)	33

Total params: 324,193
Trainable params: 324,193
Non-trainable params: 0

Epoch 1/2

accuracy: 0.5158 - val_loss: 0.6795 - val_accuracy: 0.5681

Epoch 2/2

accuracy: 0.7660 - val_loss: 0.5392 - val_accuracy: 0.7325

Accuracy: 73.25%

Модель 4:

Model: "sequential_3"

```
Layer (type)
                      Output Shape
                                          Param #
______
embedding_3 (Embedding)
                      (None, 500, 32)
                                          320000
                      (None, 64)
gru (GRU)
                                          18816
dense_6 (Dense)
                      (None, 1)
                                          65
Total params: 338,881
Trainable params: 338,881
Non-trainable params: 0
Epoch 1/2
accuracy: 0.6335 - val_loss: 0.4009 - val_accuracy: 0.8222
accuracy: 0.8534 - val_loss: 0.3783 - val_accuracy: 0.8306
Accuracy: 83.06%
    Была написана функция, вычисляющая предсказание, сделанное
ансамблем моделей:
def get_ensemble_predictions(models, sequence, round = True):
 predictions = []
 for model in models:
   curr_prediction = model.predict(sequence)
   predictions.append(curr_prediction)
 predictions = np.asarray(predictions)
 predictions = np.mean(predictions, 0)
 if round:
   predictions = np.round(predictions)
 return predictions.flatten()
    Предсказание вычисляется как среднее арифметическое предсказаний
```

Предсказание вычисляется как среднее арифметическое предсказаний всех моделей. Также была реализована функция, оценивающая точность предсказания, сделанного ансамблем моделей:

```
def evaluate_ensemble(models, x_data, y_data):
    predictions = get_ensemble_predictions(models, x_data)
    accuracy = predictions == y_data
    return np.count_nonzero(accuracy)/y_data.shape[0]
```

Точность предсказания ансамбля, состоящего из четырех приведенных выше моделей, составляет 88.12%, что больше, чем у каждой из моделей поотдельности. Пользовательский текст загружается из файла и кодируется по тем же правилам, что и обучающий датасет. Функция, осуществляющая чтение и кодирование текста, взята из лабораторной работы №6. Была

осуществлена классификация отзывов, найденных на сайте Rotten Tomatoes, при помощи ансамбля моделей. Результаты предсказания приведены ниже.

Исходный текст	Результат предсказания	
Cringy boring but easy story to follow a		
few funny moments in there as well. Actors	0.4122197 (отрицательный обзор)	
are ok but dont expect a deep story at all	0.4122197 (отрицательный оозор)	
(test1.txt)		
Mean Girls grabs the base formula of a teen		
movie and takes it to another level with clever		
jokes, an engaging plot, and many memorable	0.7108398 (положительный обзор)	
moments. The acting is better than other		
comedy/teen movies, and the visual dynamics		
and movement are well executed. (test2.txt)		
Mean Girls is one of the most iconic movies		
of all time. Every line is iconic and is quoted		
all the time. As a person who prefers movies	0.9542202 (положительный обзор)	
from the early 2000's I might be a bit bias		
when I say that Mean Girls definitely makes		
my top 10 favorite movies list. (test3.txt)		
I watched because it was on TV on a Saturday		
afternoon. I thought it was over and changed		
channels, then changed back twenty minutes	0.20072854 (отрицательный обзор)	
later. It was still playing30 minutes too ling		
and all sickening mush. (test4.txt)		

Все отзывы были классифицированы правильно.

Выводы.

В данной работе решалась задача анализа настроений при помощи ансамбля нейронных сетей. Были созданы четыре модели различной архитектуры, которые были обучены на разных выборках. За предсказание, сделанное ансамблем, принималось среднее арифметическое предсказаний всех моделей. Точность предсказания ансамбля оказалась выше, чем точность

моделей отдельно. Ансамбль сетей был каждой ИЗ предсказания пользовательском были протестирован на тексте все отзывы классифицированы правильно. В ходе лабораторной работы были также изучены принципы работы рекуррентных нейронных сетей.